

Bonferroni Correction

Sofia Dextre

Marzo 10, 2026

1 Definiciones previas

1.1 Pruebas post-hoc

Sea X un conjunto de datos aleatorios generado bajo un modelo estadístico $\{P_\theta : \theta \in \Theta\}$. Considérese una *familia* de hipótesis nulas

$$\mathcal{H} = \{H_{0,1}, H_{0,2}, \dots, H_{0,m}\},$$

donde cada $H_{0,i}$ impone una restricción sobre θ (por ejemplo, igualdad de parámetros entre grupos o independencia entre variables categóricas).

Un procedimiento de prueba múltiple puede representarse mediante un vector de decisiones

$$\boldsymbol{\delta}(X) = (\delta_1(X), \dots, \delta_m(X)), \quad \delta_i(X) \in \{0, 1\},$$

donde $\delta_i(X) = 1$ indica rechazo de $H_{0,i}$ y $\delta_i(X) = 0$ indica no rechazo.

Se denominan **pruebas post-hoc** a los contrastes aplicados a una familia $\mathcal{H}$ *después* de una etapa previa basada en los datos (por ejemplo, un contraste global o un análisis exploratorio) que motiva investigar *hipótesis específicas* dentro de $\mathcal{H}$.

1.2 Falso positivo

Considérese una única hipótesis nula H_0 con espacio paramétrico nulo $\Theta_0 \subseteq \Theta$ y una regla de decisión $\delta(X) \in \{0, 1\}$, donde $\delta(X) = 1$ denota el rechazo de H_0 .

Un **falso positivo** ocurre cuando el procedimiento rechaza una hipótesis nula que es verdadera. Formalmente, el evento de falso positivo es

$$\{\delta(X) = 1\} \cap \{\theta \in \Theta_0\}.$$

La probabilidad de falso positivo (error tipo I) bajo el parámetro θ es

$$P_\theta(\delta(X) = 1), \quad \theta \in \Theta_0.$$

El **tamaño** (o *size*) de una prueba es la *máxima* probabilidad de cometer un falso positivo cuando la hipótesis nula es verdadera. Para definirlo formalmente, sea Θ_0 el conjunto de valores del parámetro θ para los cuales H_0 es cierta. Entonces, para cada $\theta \in \Theta_0$ existe una probabilidad de rechazar H_0 aun siendo verdadera:

$$P_\theta(\delta(X) = 1).$$

Como dicha probabilidad puede cambiar según el valor específico de θ dentro de Θ_0 , se toma el peor caso (el más grande) sobre todos los escenarios compatibles con H_0 . A esa máxima probabilidad se le llama **tamaño**:

$$\alpha = \sup_{\theta \in \Theta_0} P_\theta(\delta(X) = 1).$$

Interpretación de sup (supremo). El símbolo sup significa *supremo* o *cota superior mínima*. En este contexto, puede leerse como:

$\sup_{\theta \in \Theta_0} P_\theta(\delta(X) = 1) =$ “la mayor probabilidad posible de rechazar H_0 cuando H_0 es verdadera”

Si esa mayor probabilidad se alcanza en algún valor $\theta^* \in \Theta_0$, entonces el supremo coincide con un máximo:

$$\sup_{\theta \in \Theta_0} P_\theta(\delta(X) = 1) = \max_{\theta \in \Theta_0} P_\theta(\delta(X) = 1).$$

Si no se alcanza exactamente, el supremo sigue representando el límite superior más ajustado (la mejor cota superior).

Interpretación de α . Decir que una prueba es de *nivel* α significa que, bajo cualquier situación en la que H_0 sea verdadera (es decir, para todo $\theta \in \Theta_0$),

$$P_\theta(\delta(X) = 1) \leq \alpha.$$

En palabras: *aunque el valor real de θ bajo H_0 sea el peor posible, la probabilidad de falso positivo no excede α .* Por ejemplo, si $\alpha = 0.05$, la prueba está construida para que la probabilidad de rechazar H_0 cuando es cierta sea, en el peor caso, como máximo 5%.

1.3 Family-Wise Error Rate (FWER)

Sea $\mathcal{H} = \{H_{0,1}, \dots, H_{0,m}\}$ una familia de hipótesis y $\boldsymbol{\delta}(X) = (\delta_1(X), \dots, \delta_m(X))$ el vector de decisiones asociado. Defínase el conjunto de índices de hipótesis nulas verdaderas como

$$I_0 \subseteq \{1, \dots, m\}.$$

El evento “cometer al menos un falso positivo dentro de la familia” es

$$\bigcup_{i \in I_0} \{\delta_i(X) = 1\}.$$

El **Family-Wise Error Rate (FWER)** se define como

$$\text{FWER} = P\left(\bigcup_{i \in I_0} \{\delta_i(X) = 1\}\right).$$

En términos conceptuales, FWER es la probabilidad de realizar *al menos un* rechazo incorrecto (error tipo I) dentro del conjunto de comparaciones.

2 Corrección de Bonferroni

Considérese una familia de m hipótesis nulas

$$\mathcal{H} = \{H_{0,1}, H_{0,2}, \dots, H_{0,m}\},$$

y un conjunto de pruebas individuales (una por hipótesis) con reglas de decisión $\delta_i(X) \in \{0, 1\}$, donde $\delta_i(X) = 1$ indica rechazo de $H_{0,i}$.

Sea $I_0 \subseteq \{1, \dots, m\}$ el conjunto de índices de las hipótesis nulas verdaderas. El evento “*cometer al menos un falso positivo*” es

$$\bigcup_{i \in I_0} \{\delta_i(X) = 1\}.$$

Por definición, el **Family-Wise Error Rate (FWER)** es

$$\text{FWER} = P\left(\bigcup_{i \in I_0} \{\delta_i(X) = 1\}\right).$$

La corrección de Bonferroni se basa en la **desigualdad de Boole** (o desigualdad de la unión), que establece que para eventos $A_1, \dots, A_k$,

$$P\left(\bigcup_{j=1}^k A_j\right) \leq \sum_{j=1}^k P(A_j).$$

Aplicando esta desigualdad a los eventos $A_i = \{\delta_i(X) = 1\}$ para $i \in I_0$, se obtiene:

$$\text{FWER} = P\left(\bigcup_{i \in I_0} \{\delta_i(X) = 1\}\right) \leq \sum_{i \in I_0} P(\delta_i(X) = 1).$$

Regla de Bonferroni Si cada prueba individual se construye de modo que, para todo $\theta \in \Theta_{0,i}$,

$$P_\theta(\delta_i(X) = 1) \leq \frac{\alpha}{m}, \quad i = 1, \dots, m,$$

entonces se garantiza que

$$\text{FWER} \leq \alpha$$

para cualquier configuración de hipótesis nulas verdaderas (control fuerte).

Implementación práctica (umbral ajustado). La regla anterior se implementa comúnmente usando un nivel por-prueba

$$\alpha^* = \frac{\alpha}{m},$$

y declarando significativo el contraste i si su p-valor satisface

$$p_i < \alpha^*.$$

2.1 Forma equivalente (p-valores ajustados).

La corrección de Bonferroni puede implementarse de dos maneras equivalentes:

1. **(Umbral ajustado)** Mantener los p-valores originales p_i y comparar cada uno con un nivel por-prueba

$$\alpha^* = \frac{\alpha}{m},$$

rechazando $H_{0,i}$ si $p_i < \alpha^*$.

2. **(p-valores ajustados)** Mantener el nivel global α (por ejemplo, 0.05) y transformar cada p-valor p_i en un *p-valor ajustado* p_i^{adj} , para luego decidir con la regla usual: rechazar si $p_i^{\text{adj}} < \alpha$.

Derivación de la equivalencia. Partimos de la regla de Bonferroni en su forma de umbral ajustado:

$$p_i < \frac{\alpha}{m}.$$

Como $m > 0$, al multiplicar ambos lados por m se obtiene una desigualdad equivalente:

$$m p_i < \alpha.$$

Esto sugiere definir el p-valor ajustado como

$$p_i^{\text{adj}} = m p_i,$$

de modo que la condición de rechazo se escriba de la forma habitual:

$$p_i^{\text{adj}} < \alpha.$$

Por lo tanto, decidir con $p_i < \alpha/m$ es exactamente lo mismo que decidir con $m p_i < \alpha$.

Por qué se usa $\min\{1, m p_i\}$. Un p-valor, por definición, debe pertenecer al intervalo $[0, 1]$. Sin embargo, al multiplicar por m puede ocurrir que $m p_i > 1$ (por ejemplo, si $p_i = 0.30$ y $m = 10$, entonces $m p_i = 3$). Para conservar la interpretación de “p-valor”, se recorta el resultado a lo máximo posible:

$$p_i^{\text{adj}} = \min\{1, m p_i\}.$$

En consecuencia:

$$p_i^{\text{adj}} = \begin{cases} m p_i, & \text{si } m p_i \leq 1, \\ 1, & \text{si } m p_i > 1. \end{cases}$$

Regla de decisión con p-valores ajustados. Una vez calculado p_i^{adj} , se rechaza $H_{0,i}$ si

$$p_i^{\text{adj}} < \alpha.$$

Esta regla produce *exactamente las mismas decisiones* que comparar p_i con α/m .

Interpretación de p_i^{adj} . El valor p_i^{adj} puede interpretarse como el *nivel global mínimo* (en términos de FWER bajo Bonferroni) al cual el contraste i resultaría significativo. Por ejemplo, si $p_i^{\text{adj}} = 0.04$, entonces la comparación i sería significativa bajo Bonferroni para cualquier $\alpha \geq 0.04$, y en particular para $\alpha = 0.05$.

3 ¿Cuándo usar la regla de Bonferroni?

El objetivo de usar la regla de Bonferroni es evitar los falsos positivos al hacer muchas pruebas a la vez (controlar el FWER)

$$\text{FWER} = P(\text{rechazar al menos una hipótesis nula verdadera}) \leq \alpha.$$

por lo que se contrastan simultáneamente una familia de m hipótesis $\mathcal{H} = \{H_{0,1}, \dots, H_{0,m}\}$

En resumen, Bonferroni es apropiada cuando se desea reducir falsos positivos (errores tipo I) en múltiples hipótesis.

Cuándo Bonferroni es ideal

- **Pruebas post-hoc:** después de un contraste global (por ejemplo, χ^2 , ANOVA, Kruskal–Wallis), cuando se realizan múltiples comparaciones para identificar qué grupos/categorías explican la diferencia global.
- **Análisis confirmatorio:** cuando se tiene un conjunto *predefinido* de hipótesis (pocas a moderadas) y se busca conclusiones robustas.
- **Contextos de alto costo de error tipo I:** cuando declarar una asociación o diferencia inexistente es particularmente problemático (p. ej., informes formales, decisiones clínicas/sanitarias, conclusiones regulatorias).
- **Cuando no se tiene independencia de pruebas:** Bonferroni es fácil de aplicar y su validez no requiere independencia entre pruebas, por lo que es un ajuste estándar.

Cuándo Bonferroni puede NO ser ideal.

- **Cuando m es grande:** Al ser m muy grande, α/m tiende a 0, entonces para que algo sea significativo se necesitarían p-values extremadamente pequeños también, al ser demasiado restrictivo los casos de falsos negativos aumentarían
- **En análisis exploratorio:** si el objetivo es detectar señales entre muchas hipótesis, suele preferirse controlar otras medidas (p. ej., FDR) o usar ajustes menos conservadores.