

Small Area Estimation and Fay-Herriot Model

Sofia Dextre

Marzo 14, 2026

1 ¿Qué resuelve SAE?

La Estimación en Áreas Pequeñas (Small Area Estimation, SAE) surge cuando se desea estimar un parámetro de interés para dominios muy desagregados, por ejemplo: Distritos, minicipios, etc.

El problema es que en esos dominios, el tamaño muestral suele ser pequeño. Como consecuencia, los estimadores directos basados únicamente en la encuesta presentan alta variabilidad y baja precisión, incluso pueden no existir para algunas áreas no muestreadas.

Formalmente, si θ_i representa el parámetro de interés del área i , y $\hat{\theta}_i^D$ su estimador directo, entonces el problema típico en SAE es que

$$\text{Var}(\hat{\theta}_i^D)$$

puede ser grande cuando el tamaño muestral del área i es pequeño.

2 Formulación del problema

Sea $i = 1, \dots, m$ el índice de áreas pequeñas. Para cada área i , queremos estimar un parámetro θ_i , por ejemplo una media, una proporción, una tasa o un índice de pobreza.

Disponemos de un estimador directo y_i , que aproxima a θ_i . En SAE suele escribirse

$$y_i = \hat{\theta}_i^D.$$

Este estimador directo satisface, de manera aproximada,

$$E(y_i \mid \theta_i) \approx \theta_i, \quad \text{Var}(y_i \mid \theta_i) = D_i,$$

El gran problema es que cuando D_i es grande, el estimador directo es inestable y poco confiable.

3 SAE

SAE suele dividirse en dos grandes familias.

3.1 Modelos a nivel unidad

Trabajan con microdatos, es decir, con observaciones individuales y_{ij} .

3.2 Modelos a nivel área

Trabajan con un resumen por área:

- un estimador directo y_i ,
- su varianza D_i ,
- covariables agregadas x_i .

El modelo clásico de Fay–Herriot pertenece a esta segunda familia.

4 Modelo clásico de Fay–Herriot

4.1 Estructura en dos niveles

El modelo clásico de Fay–Herriot se construye mediante dos ecuaciones.

4.1.1 Nivel 1: modelo de muestreo

$$y_i = \theta_i + e_i, \quad i = 1, \dots, m,$$

donde:

- y_i es el estimador directo,
- θ_i es el verdadero parámetro del área,
- e_i es el error de muestreo.

Se asume que

$$e_i \sim N(0, D_i),$$

y además que los errores de muestreo son independientes:

$$e_i \perp e_j \quad \text{si } i \neq j.$$

Este primer nivel modela la incertidumbre proveniente del diseño muestral.

4.1.2 Nivel 2: modelo de enlace

$$\theta_i = x_i^\top \beta + u_i,$$

donde:

- $x_i \in \mathbb{R}^p$ es el vector de covariables del área i ,
- $\beta \in \mathbb{R}^p$ es el vector de parámetros fijos,
- u_i es un efecto aleatorio de área.

Se asume que

$$u_i \sim N(0, A),$$

con

$$u_i \perp u_j \quad \text{si } i \neq j.$$

También se supone independencia entre errores de muestreo y efectos aleatorios:

$$e_i \perp u_j \quad \forall i, j.$$

4.2 Modelo combinado

Sustituyendo $\theta_i = x_i^\top \beta + u_i$ en $y_i = \theta_i + e_i$, obtenemos

$$y_i = x_i^\top \beta + u_i + e_i.$$

Este es el **modelo clásico de Fay–Herriot**.

4.3 Distribución marginal de y_i

Como

$$u_i \sim N(0, A), \quad e_i \sim N(0, D_i),$$

e independientes, entonces

$$y_i \sim N(x_i^\top \beta, A + D_i).$$

Por lo tanto,

$$E(y_i) = x_i^\top \beta, \quad \text{Var}(y_i) = A + D_i.$$

5 Forma matricial

Definamos

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}, \quad X = \begin{pmatrix} x_1^\top \\ \vdots \\ x_m^\top \end{pmatrix}, \quad u = \begin{pmatrix} u_1 \\ \vdots \\ u_m \end{pmatrix}, \quad e = \begin{pmatrix} e_1 \\ \vdots \\ e_m \end{pmatrix}.$$

Entonces el modelo se escribe como

$$y = X\beta + u + e.$$

Con

$$u \sim N(0, AI_m), \quad e \sim N(0, D),$$

donde

$$D = \text{diag}(D_1, \dots, D_m).$$

Así, marginalmente,

$$y \sim N(X\beta, V), \quad V = AI_m + D.$$

6 Predicción del parámetro de área

En el modelo clásico de Fay–Herriot, el objetivo principal no es estimar únicamente el vector de parámetros fijos β , sino **predecir el verdadero parámetro de interés del área i** , denotado por θ_i .

Recordemos que el modelo se especifica en dos niveles:

$$\begin{aligned}y_i &= \theta_i + e_i, & e_i &\sim N(0, D_i), \\ \theta_i &= x_i^\top \beta + u_i, & u_i &\sim N(0, A),\end{aligned}$$

con independencia entre e_i y u_i .

Sustituyendo la segunda ecuación en la primera, obtenemos la forma combinada del modelo:

$$y_i = x_i^\top \beta + u_i + e_i.$$

Por lo tanto, el problema de predicción consiste en construir un predictor adecuado de θ_i a partir de la información observada y_i .

6.1 ¿Qué necesitamos para la predicción?

Para derivar el predictor de θ_i , primero necesitamos calcular:

$$E(\theta_i), \quad E(y_i), \quad \text{Cov}(\theta_i, y_i), \quad \text{Var}(y_i).$$

Esperanza de θ_i

Como

$$\theta_i = x_i^\top \beta + u_i,$$

y $x_i^\top \beta$ es una cantidad fija (no aleatoria), entonces

$$E(\theta_i) = E(x_i^\top \beta + u_i) = x_i^\top \beta + E(u_i).$$

Dado que

$$u_i \sim N(0, A),$$

se tiene $E(u_i) = 0$, y por tanto

$$E(\theta_i) = x_i^\top \beta.$$

Esperanza de y_i

Usando la forma combinada

$$y_i = x_i^\top \beta + u_i + e_i,$$

tenemos

$$E(y_i) = E(x_i^\top \beta + u_i + e_i) = x_i^\top \beta + E(u_i) + E(e_i).$$

Como

$$E(u_i) = 0, \quad E(e_i) = 0,$$

resulta que

$$E(y_i) = x_i^\top \beta.$$

Covarianza entre θ_i y y_i

Ahora calculemos

$$\text{Cov}(\theta_i, y_i).$$

Sustituyendo las expresiones de θ_i y y_i ,

$$\text{Cov}(x_i^\top \beta + u_i, x_i^\top \beta + u_i + e_i)$$

$$\text{Cov}(x_i^\top \beta, x_i^\top \beta) + \text{Cov}(x_i^\top \beta, u_i) + \text{Cov}(x_i^\top \beta, e_i) + \text{Cov}(u_i, x_i^\top \beta) + \text{Cov}(u_i, u_i) + \text{Cov}(u_i, e_i).$$

Usamos las siguientes propiedades de la covarianza:

- la covarianza de una constante con cualquier variable aleatoria es cero;
- la covarianza es bilineal;
- si dos variables son independientes, su covarianza es cero.

Entonces,

$$\text{Cov}(x_i^\top \beta + u_i, x_i^\top \beta + u_i + e_i) = \text{Cov}(u_i, u_i) + \text{Cov}(u_i, e_i),$$

porque todos los términos que involucran la constante $x_i^\top \beta$ desaparecen.

Además, como u_i y e_i son independientes,

$$\text{Cov}(u_i, e_i) = 0.$$

Y como

$$\text{Cov}(u_i, u_i) = \text{Var}(u_i) = A,$$

obtenemos

$$\text{Cov}(\theta_i, y_i) = A.$$

Varianza de y_i

Partimos de

$$y_i = x_i^\top \beta + u_i + e_i.$$

Entonces

$$\text{Var}(y_i) = \text{Var}(x_i^\top \beta + u_i + e_i).$$

Usamos ahora la fórmula general

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y),$$

y su extensión a más de dos términos. Como $x_i^\top \beta$ es constante, su varianza es cero. Por tanto,

$$\text{Var}(y_i) = \text{Var}(u_i) + \text{Var}(e_i) + 2 \text{Cov}(u_i, e_i).$$

Por independencia,

$$\text{Cov}(u_i, e_i) = 0.$$

Además,

$$\text{Var}(u_i) = A, \quad \text{Var}(e_i) = D_i.$$

Así,

$$\text{Var}(y_i) = A + D_i.$$

En resumen, hemos obtenido las cuatro cantidades clave:

$$E(\theta_i) = x_i^\top \beta, \quad E(y_i) = x_i^\top \beta, \quad \text{Cov}(\theta_i, y_i) = A, \quad \text{Var}(y_i) = A + D_i.$$

6.2 Obtención de la esperanza condicional $E(\theta_i \mid y_i)$

Bajo el modelo normal, el vector aleatorio

$$\begin{pmatrix} \theta_i \\ y_i \end{pmatrix}$$

tiene distribución normal bivariada. Para variables conjuntamente normales, la esperanza condicional viene dada por la fórmula general:

$$E(U \mid V) = E(U) + \text{Cov}(U, V) \text{Var}(V)^{-1} (V - E(V)).$$

Aplicando esta fórmula con

$$U = \theta_i, \quad V = y_i,$$

obtenemos

$$E(\theta_i | y_i) = E(\theta_i) + \text{Cov}(\theta_i, y_i) \text{Var}(y_i)^{-1} (y_i - E(y_i)).$$

Ahora sustituimos, paso a paso, los resultados ya calculados:

$$E(\theta_i | y_i) = x_i^\top \beta + A(A + D_i)^{-1} (y_i - x_i^\top \beta).$$

Como en este caso todo es escalar, podemos escribir

$$(A + D_i)^{-1} = \frac{1}{A + D_i},$$

de modo que

$$E(\theta_i | y_i) = x_i^\top \beta + \frac{A}{A + D_i} (y_i - x_i^\top \beta).$$

Distribuyendo el factor,

$$E(\theta_i | y_i) = x_i^\top \beta + \frac{A}{A + D_i} y_i - \frac{A}{A + D_i} x_i^\top \beta.$$

Agrupando los términos que multiplican a $x_i^\top \beta$,

$$E(\theta_i | y_i) = \frac{A}{A + D_i} y_i + \left(1 - \frac{A}{A + D_i}\right) x_i^\top \beta.$$

Definiendo

$$\gamma_i = \frac{A}{A + D_i},$$

obtenemos

$$\tilde{\theta}_i = E(\theta_i | y_i) = \gamma_i y_i + (1 - \gamma_i) x_i^\top \beta.$$

Esta expresión muestra que el predictor de θ_i es una combinación ponderada entre:

- el estimador directo y_i ;
- la parte explicada por el modelo $x_i^\top \beta$.

6.3 Interpretación del factor de encogimiento

El término

$$\gamma_i = \frac{A}{A + D_i}$$

se denomina **factor de encogimiento** o *shrinkage factor*.

Su interpretación es inmediata:

Si D_i es pequeño. Cuando la varianza muestral del estimador directo es baja, el estimador directo es preciso. En ese caso,

$$\gamma_i \approx 1,$$

y por tanto

$$\tilde{\theta}_i \approx y_i.$$

Es decir, la predicción se apoya principalmente en la información directa de la encuesta.

Si D_i es grande. Cuando la varianza muestral es alta, el estimador directo es muy ruidoso. En ese caso,

$$\gamma_i \approx 0,$$

y entonces

$$\tilde{\theta}_i \approx x_i^\top \beta.$$

Es decir, la predicción se apoya más en la estructura del modelo.

Así, el estimador de Fay–Herriot ajusta automáticamente el peso dado al estimador directo según la precisión muestral del área.

6.4 ¿Qué es el BLUP?

Hasta ahora hemos obtenido

$$E(\theta_i | y_i) = x_i^\top \beta + \frac{A}{A + D_i} (y_i - x_i^\top \beta),$$

suponiendo conocidos β y A .

Sin embargo, en la práctica β casi nunca es conocido. Por ello, debemos estimarlo a partir de los datos. Si A se considera conocido, entonces la matriz de covarianza marginal de y es

$$V = AI_m + D,$$

y el estimador natural de β es el estimador de mínimos cuadrados generalizados:

$$\hat{\beta}(A) = (X^\top V^{-1} X)^{-1} X^\top V^{-1} y.$$

Al reemplazar β por $\hat{\beta}(A)$ en el predictor anterior, obtenemos

$$\tilde{\theta}_i(A) = x_i^\top \hat{\beta}(A) + \gamma_i (y_i - x_i^\top \hat{\beta}(A)), \quad \gamma_i = \frac{A}{A + D_i}.$$

Equivalentemente,

$$\tilde{\theta}_i(A) = \gamma_i y_i + (1 - \gamma_i) x_i^\top \hat{\beta}(A).$$

A este predictor se le llama **BLUP** (*Best Linear Unbiased Predictor*).

¿Por qué se llama BLUP? Se llama así porque, dentro de la clase de predictores:

- lineales en los datos observados,
- insesgados bajo el modelo,

es el que minimiza el error cuadrático medio de predicción cuando A es conocido.

En otras palabras, el BLUP es la versión “óptima” del predictor lineal insesgado bajo el modelo de Fay–Herriot con componente de varianza conocida.

6.5 ¿Qué es el EBLUP?

En aplicaciones reales, el problema es que A tampoco es conocido. Por tanto, no podemos calcular exactamente ni

$$\gamma_i = \frac{A}{A + D_i},$$

ni

$$\hat{\beta}(A).$$

La solución consiste en estimar A a partir de los datos, obteniendo un valor $\hat{A}$ mediante procedimientos como máxima verosimilitud (ML) o máxima verosimilitud restringida (REML).

Una vez obtenido $\hat{A}$, reemplazamos A por $\hat{A}$ en todas las expresiones anteriores:

$$\hat{\gamma}_i = \frac{\hat{A}}{\hat{A} + D_i},$$

$$\hat{\beta}(\hat{A}) = (X^\top \hat{V}^{-1} X)^{-1} X^\top \hat{V}^{-1} y, \quad \hat{V} = \hat{A} I_m + D.$$

Entonces el predictor queda

$$\hat{\theta}_i^{EBLUP} = x_i^\top \hat{\beta}(\hat{A}) + \hat{\gamma}_i (y_i - x_i^\top \hat{\beta}(\hat{A})).$$

Equivalentemente,

$$\hat{\theta}_i^{EBLUP} = \hat{\gamma}_i y_i + (1 - \hat{\gamma}_i) x_i^\top \hat{\beta}(\hat{A}).$$

A este predictor se le denomina **EBLUP** (*Empirical Best Linear Unbiased Predictor*).

¿En qué se diferencia del BLUP? La diferencia esencial es la siguiente:

- el **BLUP** asume conocido el componente de varianza A ;
- el **EBLUP** reemplaza ese valor desconocido por un estimador $\hat{A}$.

Por eso se le llama *empirical*: porque ya no usa el valor teórico verdadero de A , sino una estimación obtenida empíricamente a partir de los datos.

6.6 Conclusiones

La predicción del parámetro de área en Fay–Herriot no consiste ni en copiar el estimador directo ni en sustituirlo por una simple regresión. Lo que hace el modelo es **combinar de manera óptima la información directa y la información auxiliar**.

Así, el predictor final:

- conserva la información específica del área mediante y_i ;
- estabiliza la estimación mediante $x_i^\top \beta$;
- y ajusta automáticamente el peso de cada componente según la precisión muestral del área.

Esta es la razón por la cual el modelo de Fay–Herriot produce estimaciones más estables que las estimaciones directas cuando se trabaja con áreas pequeñas.